

Conceitos Gerais de LLMs

O que é uma LLM?

LLM é a sigla para Large Language Model (Modelo de Linguagem de Grande Escala). Modelos de linguagem são sistemas de inteligência artificial com dois propósitos principais: processar e gerar textos. Esses sistemas são geralmente baseados em redes neurais, que são uma forma computacional de simular o funcionamento do cérebro humano. Nessa técnica, em vez de neurônios, temos parâmetros, e, no caso dos LLMs, a quantidade de parâmetros ultrapassa a casa dos bilhões. Para efeito de comparação, o cérebro humano possui cerca de 100 bilhões de neurônios.

Como as LLMs são treinadas?

As LLMs são treinadas com enormes volumes de texto coletados da internet. Terabytes de textos são capturados e utilizados em um treinamento não supervisionado, permitindo que os modelos prevejam a continuação de um texto fornecido. Esse processo requer grandes servidores com clusters de placas de vídeo. O treinamento pode durar várias semanas, devido ao grande volume de dados, e é financeiramente custoso, além de ter um significativo impacto ambiental em termos de emissões de CO2. Um estudo estima que o treinamento de uma LLM com 2 bilhões de parâmetros pode custar cerca de 1,6 milhão de dólares. O resultado desse treinamento é semelhante a uma vasta compressão de dados, como um arquivo zip. De dezenas de terabytes, chegamos a um modelo com 70 bilhões de parâmetros (como o LLaMA 2 70B), que ocupa aproximadamente 140 GB. Embora essa compressão implique em perda de dados, é um trabalho notável para otimizar o uso das informações disponíveis na internet. A partir desse treinamento, obtemos uma LLM base, que ainda não é o modelo que utilizamos no ChatGPT.

Diferenças entre uma LLM Base e uma LLM treinada para instruções:

A LLM base é treinada para prever o próximo segmento de texto mais provável, dada uma entrada. Por exemplo, se fornecermos o seguinte texto a uma LLM base:

Era uma vez, um unicórnio É possível que ela nos responderia: **que vivia em uma floresta mágica**

Seria uma resposta aceitável dado o texto que eu ofereci a ela. Agora caso fizéssemos um questionamento ela, como:


Qual é a capital do Brasil? É possível que a LLM nos retornasse:

Qual é a maior cidade do Brasil?

Qual é a população do Brasil?

Uma LLM base, por sua natureza, não reconhece que está diante de um questionamento que exige uma resposta específica. Ela simplesmente fornece o texto mais provável a seguir, baseando-se em dados genéricos obtidos da internet. Por isso, respostas como a mencionada anteriormente são comuns.

Em contraste, uma LLM treinada para seguir instruções é desenvolvida para responder de maneira mais direcionada. Essas LLMs são aprimoradas a partir de uma LLM base e, em seguida, submetidas a um treinamento adicional com conjuntos de dados compostos por instruções e as respectivas respostas a essas instruções. O processo envolve a criação de milhares de instruções distintas e a colaboração de especialistas para fornecer as respostas adequadas. Com essa nova massa de dados, o modelo é treinado sobre a LLM base, aprendendo a emular o comportamento de um especialista. É como se o emaranhado de informações que o modelo possui fosse canalizado para gerar respostas que se alinham à linguagem humana. Assim, chegamos aos modelos atuais do ChatGPT, que são exemplos de LLMs treinadas para seguir instruções.



Parâmetros comuns de um modelo de LLM

- **Temperature (Temperatura):** Controla o grau de determinismo do modelo. Um modelo mais determinístico tende a escolher o token de maior probabilidade como o próximo na sequência. Aumentar a temperatura resulta em respostas mais aleatórias, incrementando a “criatividade” do modelo.
- **Top P:** Refere-se a uma técnica de amostragem conhecida como amostragem de núcleo, que também controla o determinismo do modelo. Com um valor baixo de Top P, o modelo considera apenas os tokens que compõem a massa de probabilidade do Top P, selecionando respostas mais confiáveis.

Parâmetros comuns de um modelo de LLM

- **Max Length (Tamanho Máximo):** Permite gerenciar o número de tokens que o modelo gera, ajustando o tamanho máximo. Definir um limite ajuda a evitar respostas excessivamente longas ou irrelevantes e a controlar os custos.
- **Stop Sequences (Sequências de Parada):** São cadeias de caracteres que sinalizam ao modelo para parar de gerar tokens. Especificar sequências de parada ajuda a controlar o comprimento e a estrutura da resposta. Por exemplo, para limitar uma lista a 10 itens, você pode adicionar “11” como uma sequência de parada.

Parâmetros comuns de um modelo de LLM

- **Frequency Penalty** (Penalidade de Frequência): Aplica uma penalidade ao próximo token proporcionalmente à frequência com que esse token já apareceu na resposta e no prompt. Uma penalidade de frequência mais alta reduz a probabilidade de repetição de palavras na resposta.
 - **Presence Penalty** (Penalidade de Presença): Impõe uma penalidade a tokens repetidos, mas, diferentemente da penalidade de frequência, a penalidade é a mesma independentemente da frequência da repetição. Isso evita que o modelo repita frases com muita frequência. Uma penalidade de presença mais alta pode ser usada para gerar texto mais diversificado ou criativo, enquanto uma penalidade mais baixa pode ajudar o modelo a manter o foco.

Assim como com a temperatura e o Top P, a recomendação geral é ajustar a penalidade de frequência ou de presença, mas não ambas simultaneamente.

O que é um token

Um token é um pedaço de texto em que a entrada e a saída são divididas antes do modelo processar.
Dependendo do tokenizer:

- uma palavra curta pode virar **1 token**
- uma palavra maior pode virar **2 ou mais tokens**
- espaços, pontuação e símbolos também entram na conta
- em português, muitas palavras com acento ou flexões podem quebrar em mais de um token

Exemplo aproximado:

- `olá` → 1 ou 2 tokens, dependendo do tokenizer
- `inteligência artificial` → vários tokens
- `print("oi")` → também vira vários tokens, incluindo pontuação

O que entra na contagem

Não entra só a sua pergunta “visível”. Normalmente contam também:

- instruções do sistema
- histórico da conversa enviado junto
- mensagens anteriores no contexto
- texto recuperado por RAG
- saída estruturada em JSON
- ferramentas, schemas e metadados enviados ao modelo

Ou seja: às vezes o usuário vê uma pergunta curta, mas a requisição real tem muito mais tokens.

Como a tokenização é feita

Cada modelo usa um **tokenizer** próprio, baseado em um vocabulário estatístico. Em vez de dividir o texto apenas por espaços, ele quebra em fragmentos frequentes. Por exemplo:

- palavras comuns podem existir inteiras no vocabulário
- palavras raras podem ser quebradas em pedaços menores
- código-fonte costuma ser fragmentado de forma diferente de texto natural

Isso significa que:

- **100 palavras não equivalem sempre ao mesmo número de tokens**
- o total varia por idioma, estilo de escrita e modelo

Regra prática

Uma aproximação comum é:

- **1 token $\neq$ 1 palavra**
- em inglês, 1 token costuma corresponder a cerca de **0,75 palavra**
- em português, a relação varia, mas geralmente o número de tokens pode ficar um pouco maior que o esperado para o mesmo conteúdo

Exemplo

Texto do usuário:

Explique orientação a objetos em Python com exemplos.

Isso pode parecer uma frase curta, mas a cobrança real pode incluir:

- sua frase
- instruções internas do sistema
- contexto da conversa
- resposta do modelo

Então a conta final pode ficar bem acima do texto visível.

Princípios de um bom prompt


O que é um prompt?

Um prompt é a entrada que fornecemos a um modelo de linguagem. A ideia é que, ao receber essa entrada, o modelo a processe em sua rede neural e nos forneça uma resposta. A entrada é comumente chamada de prompt.

Prompt



Modelo LLM



Resultado

Princípios de um bom prompt

1º Princípio - Escrever instruções claras e específicas

É importante entender que, apesar da aparente inteligência dos modelos de linguagem, eles ainda são scripts executados em computadores. Muitos aspectos da comunicação humana não são verbais.

Existem várias técnicas para adicionar clareza a um prompt, como definir o contexto, formatar a saída, determinar o público e a persona, além de utilizar técnicas de one-shot e few-shot prompting.

Princípios de um bom prompt

2º Princípio - Dar ao modelo tempo para pensar


Assim como os seres humanos, quanto mais tempo dermos ao modelo para “pensar”, mais refinada será a resposta. Você pode se perguntar como dar mais tempo ao modelo. Existem várias técnicas desenvolvidas que instruem o modelo a realizar seu raciocínio passo a passo. Por exemplo, se apresentarmos uma questão matemática ao modelo e pedirmos apenas uma resposta de “Correto” ou “Errado”, a probabilidade de erro é alta, pois o modelo não sabe que deve raciocinar antes de responder. Se pedirmos para ele realizar o cálculo e depois indicar se a solução está correta ou errada, a chance de acerto aumenta. Outra técnica importante é dividir um prompt maior em prompts menores e mais específicos sempre que possível.

Princípios de um bom prompt

Prompting é sobre iteratividade

O processo de criação de um bom prompt exige iteratividade. Nunca se chega a uma boa resposta na primeira tentativa. É necessário sempre realizarmos um processo contínuo de melhora de nosso prompt, de forma a obtermos constantemente respostas melhores do modelo.

Alucinações



Alucinações ocorrem quando o modelo responde com confiança a uma informação incorreta. Ele pode criar detalhes e fatos, pois possui apenas um resumo das informações que foram passadas durante seu treinamento. Vejamos um exemplo no prompt a seguir:

Fale sobre as características das escovas de dente da marca "SorriDente"

A marca SorriDente é inventada e não existe e veja o que o modelo retornou:

As escovas de dente da marca "SorriDente" são reconhecidas por suas características de alta
→ qualidade e eficiência na limpeza bucal. Algumas características das escovas de dente da
→ marca incluem:

1. Cerdas macias e resistentes: As cerdas das escovas "SorriDente" são feitas de materiais de
→ alta qualidade, o que as torna suaves para a gengiva, mas ao mesmo tempo resistentes para
→ uma limpeza eficaz dos dentes.
2. Design ergonômico: As escovas de dente da marca "SorriDente" possuem um design ergonômico
→ que proporciona maior conforto e facilidade de uso durante a escovação.
3. Durabilidade: As escovas de dente "SorriDente" são conhecidas pela durabilidade de suas
→ cerdas e materiais, garantindo uma maior vida útil do produto.
4. Diversidade de modelos: A marca oferece uma variedade de modelos de escovas de dente para
→ atender às diferentes necessidades dos consumidores, como escovas com cerdas angul

Criando prompts claros e específicos

Desenvolva um plano para uma aula sobre relatividade



Objetivo da aula: Compreender os princípios da teoria da relatividade e como ela influencia nossa compreensão do universo.



1. Introdução à teoria da relatividade:

- Breve histórico sobre Albert Einstein e a criação da teoria da relatividade.
- Explicação dos conceitos de relatividade restrita e relatividade geral.

2. Princípios da relatividade restrita:

- Discussão sobre a invariância das leis da física em diferentes sistemas de referência.
- Explicação da dilatação do tempo e contração do espaço.
- Exemplos práticos de como esses princípios se aplicam em situações do nosso cotidiano.

Clareza

Eu sou um professor de Física de 8ª série preparando uma aula sobre relatividade. Desenvolva um plano de aula.



Plano de aula sobre relatividade para a 8ª série:



Objetivo da aula:

- Compreender os princípios básicos da teoria da relatividade de Einstein.

Materiais necessários:

- Quadro negro ou branco;
- Giz ou marcador;
- Computador ou projetor para apresentação de slides.

Estratégias de ensino:

Especificidade

Eu sou um professor de Física de 8ª série preparando uma aula sobre relatividade. Desenvolva um plano de aula para uma turma de 20 alunos que durará 2 horas. Na sala teremos projetor, quadro branco e computadores para utilização.



Plano de aula sobre Relatividade para 8ª série:



Objetivo da aula: Introduzir os conceitos básicos da Teoria da Relatividade de Albert Einstein e como ela transformou nossa compreensão do Universo.

Materiais necessários:

- Projetor
- Quadro branco
- Computadores com acesso à internet
- Material visual para ilustrar os conceitos (vídeos, animações, etc.)

Problemas a serem evitados:

Sobrecarga

A sobrecarga está relacionada à adição de muita informação irrelevante no prompt. Ao tentarmos aumentar a clareza, adicionando um contexto ao prompt, podemos incluir informações não necessárias para a instrução que darei ao modelo. Portanto, tenha cuidado e adicione apenas o necessário!

Problemas a serem evitados:

Ambiguidade

Você está tentando adicionar clareza, portanto, não seja ambíguo. Por exemplo, caso não saibamos quantos alunos assistirão à nossa aula sobre relatividade, não crie um prompt da seguinte forma:

Desenvolva um plano de aula para uma turma de 5 a 30 alunos

Melhor então seria criar múltiplos prompts, que se encaixariam nas diversas situações:

Desenvolva um plano de aula para uma turma de 5 alunos

Problemas a serem evitados:

Complicando demais

Ajude o modelo a fornecer respostas eficazes. Portanto, evite o uso de termos técnicos muito complexos, jargões, expressões idiomáticas pouco comuns ou frases muito complexas. Tudo isso dificulta o trabalho do modelo. Portanto, seja claro e específico, mas sempre com simplicidade!

Elementos de um prompt

- Instrução: a tarefa específica a ser realizada pelo modelo
- Contexto: informação externa ou contexto adicional que auxilia o modelo a atingir melhores respostas
- Dados de entrada: a entrada ou questão que estamos interessados na resposta
- Indicador de Saída: o tipo ou formato da saída

Elementos de um prompt

Contexto

Eu sou um assessor financeiro de pessoas jovens, com até 30 anos de idade e com baixo poder aquisitivo. Ajudo elas a desenvolverem uma educação financeiro e formo planos adequados para longo prazo, para clientes que querem começar cedo a investir pensando em suas aposentadorias.

Instrução

Desenvolva um plano de investimento eficaz, definindo tipos de investimentos, proporções entre investimentos e diversificação para o perfil do cliente abaixo.

Dados de Entrada

Um homem de 25 anos, com baixa propensão a risco e consegue aportar 1000 reais por mês em novos investimentos. Hoje ele já possui 50 mil reais investidos em ações.

Indicador de Saída

Plano de investimento:

Persona

Escreva uma história curta de magia no estilo da J.K. Rowling



Escreva um poema ao estilo de um poeta brasileiro do romantismo



Eu sou um assessor financeiro de pessoas jovens, com até 30 anos de idade e com baixo poder aquisitivo. Ajudo elas a desenvolverem uma educação financeiro e formo planos adequados para longo prazo, para clientes que querem começar cedo a investir pensando em suas aposentadorias.



Público

Escreva uma história simples de magia pra crianças tem medo do escuro



Desenvolva um plano de aula sobre relatividade para alunos estudando para o Vestibular.



Exemplos



Aqui está um exemplo do meu estilo de escrita de emails:

####

Fala, meu amigo!

Como estamos?

O que você acha de marcamos um dia para conversar?

Tamo junto!

Abraço

####

Imitando o estilo do email anterior, crie um novo email para realizar a ação a seguir.
Marcar uma conversa no "Bar do Antonio" às 20h e avisar que você convidou o Pedro também.

Delimitadores

O que são delimitadores?

Os delimitadores delimitam os trechos mais importantes no prompt, elementos que não podem passar despercebidos pelo modelo. Podemos utilizar diversos delimitadores, como ####, "", -, etc. Anteriormente demos um exemplo de delimitador ao fazermos o prompt para criação de e-mails:

Aqui está um exemplo do meu estilo de escrita de emails:

####

Fala, meu amigo!

Como estamos?

O que você acha de marcamos um dia para conversar?

Tamo junto!

Abraço

####

Imitando o estilo do email anterior, crie um novo email para realizar a ação a seguir.
Marcar uma conversa no "Bar do Antonio" às 20h e avisar que você convidou o Pedro também.

Saídas estruturadas

Determinar o formato da saída:

- **Uma lista de Python**
 - **No formato JSON**
- **Uma tabela HTML**

...

Zero, One e Few-Shot

As técnicas de one e few-shot são bastante conhecidas. Na prática, elas não passam de formas de passar exemplos de respostas para “inspirar” o modelo a responder mais de acordo.

Zero, One e Few-Shot

Zero Shot

Os modelos de LLM atuais são ajustados para seguir instruções e treinados com uma quantidade enorme de dados. Logo, eles são capazes de realizar tarefas “zero-shot”, ou seja, tarefas sem receber um exemplo anterior.

Classifique o texto como neutro, negativo ou positivo.

Texto: Eu acho que as férias estão ok.

Sentimento:

Neutro

Zero, One e Few-Shot

Utilizando a Técnica One-Shot

Na abordagem de prompting one-shot, o modelo aprende com o contexto fornecido, e essa orientação adicional permite um desempenho melhor. As demonstrações funcionam como condicionamento para exemplos subsequentes nos quais gostaríamos que o modelo gerasse uma resposta. No caso do one-shot, fornecemos apenas uma demonstração para o modelo.

Vamos dar um exemplo:

Um "whatpu" é um animal pequeno e peludo nativo da Tanzânia. Um exemplo de uma frase que usa a

→ palavra whatpu é:

Estávamos viajando na África e vimos esses whatpus muito fofos.

Realizar um "farduddle" significa pular para cima e para baixo muito rápido. Um exemplo de uma

→ frase que usa a palavra farduddle é:

A criança estava tão animada que começou a farduddle de alegria.

Zero, One e Few-Shot

A diferença de one-shot para few-shot é apenas a quantidade de exemplos que são fornecidos ao modelo. No caso de one-shot, uma demonstração é dada, enquanto no few-shot, múltiplas demonstrações são dadas.

Zero, One e Few-Shot

Formatações Few-shot

Podemos utilizar diferentes formatações para realizar o few-shot:

Isso é incrível! /// Positivo

Isso é ruim! // Negativo

Uau, esse filme foi incrível! // Positivo

Que programa horrível! //

Negativo

Outra possível formatação seria a seguinte:

Texto: Isso é incrível!

Sentimento: / Positivo

Texto: Isso é ruim!

Sentimento: Negativo

Texto: Uau, esse filme foi incrível!

Sentimento: Positivo

Texto: Que programa horrível!

Sentimento:

Negativo

E uma muito utilizada é de pergunta e resposta:

...

Pergunta: Em qual país se fala a seguinte frase - "¡Hola! ¿Qué tal?"

Resposta: Espanã 🇪🇸

Pergunta: Em qual país se fala a seguinte frase - "Hello, Gentlemen"

Resposta: England 🇬🇧

Pergunta: Em qual país se fala a seguinte frase - "Wie geht's?"

Resposta:

...

Alemanha 🇩🇪



Zero, One e Few-Shot

Limitações de Few-shot

Para problemas que exigem um raciocínio mais apurado do modelo, a técnica few-shot não é recomendada. Ao mostrarmos exemplos neste caso, o modelo não consegue entender o padrão que leva à resposta.

Os números ímpares neste grupo somam um número par: 4, 8, 9, 15, 12, 2, 1.

Resposta: A resposta é Falsa.

Os números ímpares neste grupo somam um número par: 17, 10, 19, 4, 8, 12, 24.

Resposta: A resposta é Verdadeira.

Os números ímpares neste grupo somam um número par: 16, 11, 14, 4, 8, 13, 24.

Resposta: A resposta é Verdadeira.

Os números ímpares neste grupo somam um número par: 17, 9, 10, 12, 13, 4, 2.

Resposta: A resposta é Falsa.

Os números ímpares neste grupo somam um número par: 15, 32, 5, 13, 82, 7, 1.

Resposta:

A resposta é Verdadeira.

A resposta correta é “Falsa”, e podemos ver que nos casos em que há necessidade de um raciocínio mais elaborado, a técnica few-shot pode não ser suficiente para atingirmos resultados melhores.

Dando tempo para o modelo pensar

Determine se a solução do aluno está correta ou não.



Pergunta:

Estou construindo uma instalação de energia solar e preciso de ajuda com as contas de custos as finanças.

- O terreno custa R\$ 100 / metro quadrado
- Posso comprar painéis solares por R\$ 250 / metro quadrado
- Negocieei um contrato de manutenção que me custará R\$ 100 mil por ano e R\$ 10 adicionais por metro quadrado

Qual é o custo total para o primeiro ano de operações em função do número de pés quadrados.

Solução do aluno:

Seja x o tamanho da instalação em metros quadrados.

Custos:

1. Custo do terreno: $100x$
2. Custo do painel solar: $250x$
3. Custo de manutenção: $100.000 + 100x$

Custo total: $100x + 250x + 100.000 + 100x = 450x + 100.000$

Dando tempo para o modelo pensar

Resposta apresentada:

A solução do aluno está correta. O custo total para o primeiro ano de operações em função do número de metros quadrados é dado por $450x + 100.000$.



Mas na realidade a resposta está incorreta, o valor final deveria ser $360x + 100.000$. Vamos ver o que ocorre quando pedimos pro modelo pensar passo a passo:

Dando tempo para o modelo pensar

Determine se a solução do aluno está correta ou não.

Pergunta:

Estou construindo uma instalação de energia solar e preciso de ajuda com as contas de custos
→ as finanças.

- O terreno custa R\$ 100 / metro quadrado
- Posso comprar painéis solares por R\$ 250 / metro quadrado
- Negocieei um contrato de manutenção que me custará R\$ 100 mil por ano e R\$ 10 adicionais por
→ metro quadrado

Qual é o custo total para o primeiro ano de operações
em função do número de pés quadrados.

Solução do aluno:

Seja x o tamanho da instalação em metros quadrados.

Custos:

1. Custo do terreno: $100x$
 2. Custo do painel solar: $250x$
 3. Custo de manutenção: $100.000 + 10x$
- Custo total: $100x + 250x + 100.000 + 10x = 450x + 100.000$

Pense passo a passo

Dando tempo para o modelo pensar

E a solução:

A solução do aluno está parcialmente correta.

No entanto, o custo total incorreto para o primeiro ano de operações em função do número de

↪ metros quadrados. O aluno considerou corretamente os custos do terreno, dos painéis

↪ solares e da manutenção, mas não somou esses custos corretamente.

O custo total para o primeiro ano de operações em função do número de metros quadrados seria:

Custo total = Custo do terreno + Custo dos painéis solares + Custo de manutenção

Custo total = $180x + 250x + 100.000 + 10x$

Custo total = $360x + 100.000$

Portanto, a expressão correta para o custo total em função do número de metros quadrados seria

↪ $360x + 100.000$.

Cadeia de Pensamento (COT)

Cadeia de pensamento (do inglês, chain of thought) é uma técnica similar, mas nela explicamos exatamente os passos que queremos que o modelo percorra para resolver corretamente a instrução.

Determine se a solução do aluno está correta ou não.

Pergunta:

Estou construindo uma instalação de energia solar e preciso de ajuda com as contas de custos as finanças.

- O terreno custa R\$ 100 / metro quadrado
- Posso comprar painéis solares por R\$ 250 / metro quadrado
- Negocieei um contrato de manutenção que me custará R\$ 100 mil por ano e R\$ 10 adicionais por metro quadrado

Qual é o custo total para o primeiro ano de operações em função do número de pés quadrados.

Solução do aluno:

Seja x o tamanho da instalação em metros quadrados.

Custos:

1. Custo do terreno: $100x$
 2. Custo do painel solar: $250x$
 3. Custo de manutenção: $100.000 + 100x$
- Custo total: $100x + 250x + 100.000 + 100x = 450x + 100.000$

Elabore primeiro a sua própria solução para o problema. Depois, compare sua solução a solução do aluno e verifique se ela está correta.

Cadeia de Pensamento (COT)

Minha solução:

1. Custo do terreno: $R\$ 100 * x$
2. Custo dos painéis solares: $R\$ 250 * x$
3. Custo de manutenção: $R\$ 100.000 + R\$ 10 * x$

Custo total para o primeiro ano de operações:

Custo total = Custo do terreno + Custo dos painéis solares + Custo de manutenção

Custo total = $R\$ 100x + R\$ 250x + R\$ 100.000 + R\$ 10x$

Custo total = $R\$ 360x + R\$ 100.000$

Agora, vamos comparar nossa solução com a solução do aluno:

Nossa solução: Custo total = $R\$ 360x + R\$ 100.000$

Solução do aluno: Custo total = $R\$ 450x + R\$ 100.000$

Portanto, a solução do aluno está incorreta. O custo total para o primeiro ano de operações em função do número de metros quadrados é de $R\$ 360x + R\$ 100.000$, e não de $R\$ 450x + 100.000$

Encadeamento (Chaining)

Outra forma de aumentarmos o tempo de processamento de uma informação pelo modelo é quebrando um prompt em prompts menores e mais específicos. Essa técnica é fundamental ao criarmos aplicações mais sofisticadas, como ChatBots que analisam dados proprietários para gerar uma resposta ao cliente.

Vamos seguir no mesmo exemplo da aula anterior. Uma forma ainda melhor de chegar a respostas estáveis para prompts como o anterior, que verifica se a resolução de um problema foi realizada corretamente, seria: - Criando um prompt para a resolução do problema em si - E depois passando a resposta obtida anteriormente para um novo prompt que compararia com a solução do aluno

Encadeamento (Chaining)

Solucione a pergunta abaixo:



Pergunta:

Estou construindo uma instalação de energia solar e preciso de ajuda com as contas de custos as finanças.

- O terreno custa R\$ 100 / metro quadrado
- Posso comprar painéis solares por R\$ 250 / metro quadrado
- Negocieei um contrato de manutenção que me custará R\$ 100 mil por ano e R\$ 10 adicionais por metro quadrado

Qual é o custo total para o primeiro ano de operações em função do número de metros quadrados.

Solução:

Encadeamento (Chaining)

Vamos chamar o número de metros quadrados de "x".

O custo total será a soma dos custos do terreno, dos painéis solares e da manutenção.

Custo do terreno: R\$ 100 * x

Custo dos painéis solares: R\$ 250 * x

Custo da manutenção: R\$ 100.000 + R\$ 10 * x

Custo total = Custo do terreno + Custo dos painéis solares + Custo da manutenção

Custo total = R\$ 100x + R\$ 250x + R\$ 100.000 + R\$ 10x

Custo total = R\$ 360x + R\$ 100.000

Portanto, o custo total para o primeiro ano de operações em função do número de metros quadrados será de R\$ 360x + R\$ 100.000.

Encadeamento (Chaining)

Para o prompt2, modificamos a instrução inicial para:

Determine se a solução do aluno está correta ou não

Acrescentamos a pergunta original, a resposta correta gerada pelo prompt anterior, e teremos então, uma nova solução.

Determine se a solução do aluno está correta ou não.



Pergunta:

Estou construindo uma instalação de energia solar e preciso de ajuda com as contas de custos as finanças.

- O terreno custa R\$ 100 / metro quadrado
- Posso comprar painéis solares por R\$ 250 / metro quadrado
- Negocieei um contrato de manutenção que me custará R\$ 100 mil por ano e R\$ 10 adicionais por metro quadrado

Qual é o custo total para o primeiro ano de operações em função do número de pés quadrados.

Solução correta:

Vamos chamar o número de metros quadrados de "x".

O custo total será a soma dos custos do terreno, dos painéis solares e da manutenção.

Custo do terreno: $R\$ 100 * x$

Custo dos painéis solares: $R\$ 250 * x$

Custo da manutenção: $R\$ 100.000 + R\$ 10 * x$

Custo total = Custo do terreno + Custo dos painéis solares + Custo da manutenção

Custo total = $R\$ 100x + R\$ 250x + R\$ 100.000 + R\$ 10x$

Custo total = $R\$ 360x + R\$ 100.000$

Portanto, o custo total para o primeiro ano de operações em função do número de metros quadrados será de $R\$ 360x + R\$ 100.000$.

Solução do aluno:

Seja x o tamanho da instalação em metros quadrados.

Custos:

1. Custo do terreno: $100x$

2. Custo do painel solar: $250x$

3. Custo de manutenção: $100.000 + 100x$

Custo total: $100x + 250x + 100.000 + 100x = 450x + 100.000$

Resposta1 + prompt2

Resposta2

A solução do aluno está incorreta. O custo total calculado pelo aluno está incorreto. A forma correta de calcular o custo total para o primeiro ano de operações em função do número de metros quadrados é $R\$ 360x + R\$ 100.000$, como apresentado na solução correta.

Conectando-se a um LLM

Para criar um script em Python que conecte-se a um modelo, precisamos de:

- a) Uma chave de API**
- b) A biblioteca cliente da API**